

XXVI SIMPÓSIO BRASILEIRO DE CIBERSEGURANÇA · SBSEG 2026

1 a 4 de setembro de 2026 · Armação dos Búzios, RJ



Toward Agentic Intrusion Detection in the Internet of Things: Rule Generation and Live Validation for XRCE-DDS Attacks



Matheus Ciocca · Emanuel Ferreira · Tuigg Barcelos · Silvio Quincozes · Diego Kreutz · Paulo Souza

AI Horizon Labs · Universidade Federal do Pampa (UNIPAMPA)

Programa de Pós-Graduação em Engenharia de Software (PPGES)



O problema

Regras de IDS plausíveis na sintaxe ainda falham quando encontram ataques IoT reais e variantes evasivas.

1/4

Baseline

Regra inicial detectou o ataque canônico.

4

Cenários

Ataques XRCE-DDS avaliados ao vivo.

AO VIVO

Validação

Evasões aparecem apenas na execução.

Sintaxe válida não garante detecção

- Protocolos emergentes exigem semântica específica.
 - Repositórios públicos cobrem pouco XRCE-DDS.
- Variações simples quebram assinaturas compactas.
 - Payload, taxa, fragmentação e sessão mudam.
- Validação estática não testa o comportamento.
 - É preciso executar ataque, regra e tráfego benigno.
 - 3 de 4 regras iniciais falharam no ataque canônico.

O que já existe e o que falta


Abordagem	Validação	Lacuna que permanece
Regras via LLM Meng '26 · Lian '25 · Li '25	Estática ou teórica	A regra nunca enfrenta um atacante
WAF Fu & Williams '26	Reativa	Só corrige depois da evasão em produção
IoT genérico Adewole '25 · Singh '24	Estática ou emulada	Tráfego fixo, sem variantes evasivas
Rules Farmer (Este trabalho)	Ao vivo, em laço fechado	Fecha o laço: gera, ataca e refina

01


Rules Farmer fecha o ciclo

Defesa gera a regra; ataque tenta quebrá-la;
alertas orientam a próxima rodada

A arquitetura do Rules Farmer




1 · A defesa sintetiza a regra



Intenção em linguagem natural vira uma regra Snort 3 implantada

2 · Barreira 1 — tráfego benigno



Regra que alerta em tráfego legítimo é rejeitada antes de qualquer ataque

3 · Barreira 2 — ataque adversarial

O que é o Agente de Ataque?

Lê a regra ativa e cria uma variante do ataque, tentando escapar da detecção do IDS.

1
INTENÇÃO DO USUÁRIO

ORQUES-
TRADOR

AGENTE DE DEFESA

3
ENRIQUECER
INTENÇÃO

4
GERAR
REGRA

5
VALIDAR
SINTAXE

6
IMPLANTAR
NO IDS

7
TRÁFEGO
BENIGNO
PASSA?

SIM

8a

IDS
Snort 3

NÃO

8b

16

veredito do Snort 3

C

AGENTE DE ATAQUE

9
10
DEFINIR
ATAQUE

11
ESTRATÉGIA
DE EVASÃO

12
GERAR
VARIANTE

13
EXECUTAR
NO DOCKER

14


vítima monitorada

17(b) · DETECTOU → gera nova variante

17(a) · EVADIU → gera nova regra

O atacante lê a regra implantada e gera uma variante para evadi-la

4 · O laço fecha no veredito do IDS



Evadiu → nova regra. Detectou → nova variante. 20 seguidas = convergiu

02 Avaliação experimental

167 execuções em quatro cenários XRCE-DDS

O testbed executa a regra e o ataque de ponta a ponta

Item	Configuração
Cenários	UDP DoS · Malformed Inject · Session Hijack · Fragment Abuse
Orçamento	50 execuções por cenário
Convergência	20 detecções consecutivas
Ambiente	Docker · Snort 3 · deepseek-v4-pro



Código, cenários, regras
e as 167 execuções

A validação ao vivo convergiu nos quatro cenários

167

Execuções

Incluem busca de regras e a rodada final de convergência.

142

Variantes

Geradas para evadir a regra ativa em cada cenário.


4/4

Convergiram

Todas sobreviveram a 20 detecções adversariais consecutivas.

Convergir exigiu buscar, não apenas validar

Por trás dos 167 execuções e 142 variantes: cada campanha buscou a regra certa até convergir.



Linha do tempo por execução. Verde: detecção; vermelho: evasão; linhas finas: regeneração das regras; azul: início da execução convergente.

O que os resultados sustentam

- O baseline sintático detectou só 1 de 4 ataques canônicos.
- 71 de 72 regras usaram `detection_filter`.
- UDP DoS inverteu a hipótese: de pacotes pequenos/alta taxa para pacotes grandes/baixa taxa.

O que ainda não podemos afirmar

- Robustez operacional fora do testbed.
- Generalização além de quatro cenários e um IDS.
- Falsos positivos sob tráfego misto e custo do LLM.

03 Conclusões

A regra só merece confiança depois de enfrentar tráfego adversarial

O que o Rules Farmer entrega

Contribuição

Ferramenta
agêntica, de código
aberto, que gera,
implanta e testa
regras Snort 3.

Evidência

3/4 regras iniciais
falharam; as quatro
campanhas
convergiram.

Impacto

Defensores
fortalecem
assinaturas IoT
antes da produção.

A demonstração cabe em um único host

- Síntese → gate benigno → mutação → rebuild → alerta do Snort.
- Modo seguro: Snort 3 lê o arquivo; o ataque não sai na rede.
- Replay dos artefatos roda sem o LLM.
- Requisitos: Docker, Snort 3, Python 3.12, API.

Selos Adquiridos



Obrigado!

Perguntas são bem-vindas

AUTOR DE CONTATO

Matheus Martins Ciocca

matheusciocca.aluno@unipampa.edu.br

AI Horizon Labs · UNIPAMPA · PPGES



GitHub



Vídeo