

XXVI SIMPÓSIO BRASILEIRO DE CIBERSEGURANÇA · SBSEG 2026

1 a 4 de setembro de 2026 · Armação dos Búzios, RJ

Statistical Ranking: A Voting-Based Ensemble Approach to Feature Selection in Android Malware Detection




Anna Luiza Gomes, Lucas Ferreira, Angelo Gaspar, Diego Kreutz, Dionatan Schmidt, Rodrigo Mansilha e Kayuã Paim

AI Horizon Labs · Universidade Federal do Pampa (UNIPAMPA)
Programa de Pós-Graduação em Engenharia de Software (PPGES)

ABERTURA

Problema



modelos de aprendizado
de máquina

Problema: A Explosão da Dimensionalidade



Dataset	Features		Samples		
	N. Features	Feature Type	Malwares	Benign	Total
AndroCrawl	81	API Calls (24) Intents (8) Permissions (49)	10,170	86,562	96,732
ADROIT	166	Permissions	3,418	8,058	11,476
Android Permissions	183	Permissions	20,000	9,999	29,999
DefenseDroid	2938	Permissions (1490) Intents (1448)	6,000	5,975	11,975
DREBIN-215	215	API Calls (73) Permissions (113) System Commands (6) Intents (23)	5,555	9,476	15,036
KronoDroid Disp. Real	246	Permissions (146) System Calls (100)	41,382	36,755	78,137
MH-100K	24833	API Calls (24417) Intents (250) Permissions (166)	9,800	92,134	101,934
MH-1M	23247	API Calls (22394) Intents (407) Permissions (214) Opcodes (232)	119,094	1,221,421	1,340,515

Table 1. Summarization of most common Android malware datasets.

Desafios Técnicos na Seleção de Features

x1	x2	Y	n
0	0	0	50
0	1	1	50
1	0	1	50
1	1	0	50

Avalia uma feature
por vez

Informação Mútua — $I(X_i ; Y)$

x1	0
x2	0

Random Forest — importância Gini

x1	0,51
x2	0,49

Desafios Técnicos na Seleção de Features

x1	x2	Y	n
0	0	0	50
0	1	1	50
1	0	1	50
1	1	0	50

Avalia as features
em conjunto

Informação Mútua — $I(X_i ; Y)$

x1	0
x2	0

Random Forest — importância Gini

x1	0,51
x2	0,49

Lacunas no Estado da Arte


Abordagem	Limitação	Nossa solução
Wrappers (DroidRL, SigAPI)	Wrapper caro	Filtro eficiente
Filtros Únicos (CorrNetDroid)	Viés univariado / falha em interações	Múltiplas modalidades
Ensembles Simples (EnFeSTDroid)	Rankers redundantes (TF-IDF)	Rankers complementares

01

A Solução: Statistical Ranking

A contribuição central do trabalho

Statistical Ranking




Statistical Ranking



Fase inicial

COLUNA com **BAIXA** variância
(quase constante)



Uplicativo	Valor (0/1)
Aplicativo 1	0
Aplicativo 2	0
Aplicativo 3	0
Aplicativo 4	0
Aplicativo 5	0
Aplicativo 6	0
Aplicativo 7	0
Aplicativo 8	0
Aplicativo 9	0
Aplicativo 10	0
...	...

COLUNA com **ALTA** variância
(muita variação)



Aplicativo	Valor (0/1)
Aplicativo 1	1
Aplicativo 2	0
Aplicativo 3	1
Aplicativo 4	0
Aplicativo 5	1
Aplicativo 6	0
Aplicativo 7	1
Aplicativo 8	1
Aplicativo 9	0
Aplicativo 10	1
...	...

COLUNA **REMOVIDA** por
BAIXA variância



Uplicativo	Valor (0/1)
Aplicativo 1	1
Aplicativo 2	1
Aplicativo 3	1
Aplicativo 4	1
Aplicativo 5	1
Aplicativo 6	1
Aplicativo 7	1
Aplicativo 8	1
Aplicativo 9	1
Aplicativo 10	1
...	...

Regra aplicada na Fase Inicial



Se variância **< 0.01**
→ remover COLUNA



Se variância **≥ 0.01**
→ manter COLUNA

Fase inicial



App	(0 = não possui, 1 = possui)
App 1	1
App 2	1
App 3	0
App 4	1
App 5	1
App 6	0
App 7	1
App 8	1
App 9	0
App 10	1
...	...



App	(0 = não possui, 1 = possui)
App 1	1
App 2	1
App 3	0
App 4	1
App 5	1
App 6	0
App 7	1
App 8	1
App 9	0
App 10	1
...	...



Correlação (Pearson)

$r = 0,97$




Correlação > 95%




As duas permissões carregam praticamente a mesma informação.


Statistical Ranking




Statistical Ranking




Statistical Ranking



Statistical Ranking



Statistical Ranking



02 Avaliação experimental

Como validamos a proposta

Configuração experimental

Item	Configuração
Conjunto de dados	11 datasets públicos de malware Android, abrangendo permissões, chamadas de API e centralidades de grafos (ex.: AndroCrawl, Drebin, MH100K)
Baselines	Lasso, RFE (Recursive Feature Elimination) e SemiDroid. Comparação também com variações do próprio método (ablação).
Métricas	Precisão, Recall, F1-score, Acurácia, redução dimensional (%) e tempo de treinamento.
Ambiente	Intel Core i7-1165G7, 8 núcleos lógicos, 23,2 GB RAM, Ubuntu 24.04.4, Python 3.12.3, scikit-learn 1.8.0, NumPy 2.4.4, SciPy 1.17.1, pandas 3.0.2. Semente aleatória fixa (random_state=42).

Datasets

Name	Samples	Features	Benigns(original)	Malwares(original)
adroit	11476	166	8058	3418
android_permissions	26864	151	9077	17787
androcrawl	96744	141	86574	10170
defensedroid_prs	11975	2877	5975	6000
drebin215	15031	215	9476	5555
kronodroid_real_device	78137	286	36755	41382
kronodroid_emulator	63991	286	35246	28745
defensedroid_a_c	10476	4274	5222	5254
defensedroid_a_d	10476	6002	5222	5254
defensedroid_a_k	10476	6002	5222	5254
mh100k	101975	24833	92175	9800

Baselines

- RFE (Recursive Feature Elimination)
- Semidroid
- Lasso

3 melhores métodos
MH-FSF




Métricas usadas na avaliação dos resultados

- Recall
- F1 Score
- Precisão
- AUC
- Acurácia
- Percentual de redução de features

O tempo de execução é diretamente influenciado pelo % de redução de features

Resultados




Resultados - Métodos de redução selecionados

5/11

Dataset	Método
mh100k	statistical
kronodroid_real_device	statistical
kronodroid_emulator	statistical
drebin215	rfe
defensedroid_prs	semidroid
defensedroid_a_k	rfe
defensedroid_a_d	rfe
defensedroid a c	rfe
android_permissions	statistical
androcrawl	statistical
adroit	rfe


Resultados

Impacto da Redução de Features no Recall Média entre classificadores por dataset



Resultados

Impacto da Redução de Features no Recall Média entre classificadores por dataset



Resultados em três números

89,8%

Redução de Features

0.04

Queda Mediana de
Recall

8.1x

Treinamento Mais
Rápido

Discussão e ameaças à validade

O que os resultados sustentam

é o avaliador
multivariado
indispensável

Configuração	CrITÉrios Utilizados	Trade-off	Estabilidade (KI)
C6	MI + RF (sem χ^2)	85,05	85,1
C3	RF only	84,89	86,0
(Este trabalho)	χ^2 + RF (sem MI)	84,70	89,3
C2	χ^2 + MI + RF	84,34	88,5
C4	MI only	83,56	86,2
C1	χ^2 + MI (sem RF)	83,44	91,4
	χ^2 only	83,32	98,1

Discussão e ameaças à validade

O que os resultados sustentam

ponto ideal que
maximiza o
trade-off

Configuração	Crítérios Utilizados	Trade-off	Estabilidade (KI)
C6	MI + RF (sem χ^2)	85,05	85,1
C3	RF only	84,89	86,0
C5	χ^2 + RF (sem MI)	84,70	89,3
C7 (Este trabalho)	χ^2 + MI + RF	84,34	88,5
C2	MI only	83,56	86,2
C4	χ^2 + MI (sem RF)	83,44	91,4
C1	χ^2 only	83,32	98,1

Limitações do estudo

**Random Forest em
papel duplo**

Teste Wilcoxon com $n=5$

**Concept drift não foi
avaliado**

**Apenas classificadores
tabulares testados**

03 Conclusões

O que fica e para onde vamos

Considerações finais

Contribuição

Consenso
multi-perspectiva
com orçamento
adaptativo.

Evidência

Validação em
larga escala
cruzando **11**
datasets.

Impacto

O pipeline
devolve
viabilidade
operacional de
longo prazo.

Trabalhos futuros

- **Estabilidade Temporal:** Avaliar o modelo sob concept drift contínuo utilizando dados longitudinais.
- **Limiares Adaptativos:** Substituir o limiar fixo de votação por regras aprendidas por base de dados usando meta-learning.
- **Novas Arquiteturas:** Estender e avaliar a generalização em modelos puramente baseados em grafos ou sequências complexas.

Obrigada!

Perguntas são bem-vindas

AUTOR DE CONTATO

Anna Luiza Gomes

annaluiza.aluno@unipampa.edu.br

AI Horizon Labs · UNIPAMPA · PPGES

Artigo



Artefato




Slides reserva

Material de apoio para responder perguntas: detalhes de método, tabelas completas e provas.

Resultados


Impacto da Redução de Features no Recall Média entre classificadores por dataset



Métodos Estatísticos


- **Chi-Quadrado:** Mede dependência entre feature e a classe.

Exemplo — permissão SEND_SMS em 200 apps (80 malware, 120 benignos):



Métodos Estatísticos

- **Informação Mútua:** Mede quanto uma feature reduz a incerteza da classe



Métodos Estatísticos

- **Random Forest Importance:** Usa um modelo real para ver importância das features

