

XXVI SIMPÓSIO BRASILEIRO DE CIBERSEGURANÇA · SBSEG 2026

1 a 4 de setembro de 2026 · Armação dos Búzios, RJ

MulitaMiner: Avaliação Multi-Versão de Extração de Relatórios de Vulnerabilidade com LLMs



Beatriz Machado, Douglas Lautert, Cristhian Kapelinski, Diego Kreutz, Isadora Garcia Ferrão e Alessandro Bof

AI Horizon Labs | PPGES - Universidade Federal do Pampa (UNIPAMPA)

Université de Bretagne Occidentale (UBO)

ABERTURA

O acervo cresce, a triagem não acompanha



Scanners geram PDFs

CSIRTs varrem as aplicações, e cada varredura vira um relatório.

Leitura manual

Sem dado estruturado, a análise exige leitura de cada relatório.

Triagem atrasada

Sem consulta e priorização, a resposta demora.

O que já existe e o que falta

Trabalho	Entrada	Modelos	Avaliação
Gao et al. 2022	Threat intelligence	BERT	Precisão e recall
Park e Lee 2022	Relatórios técnicos	ML supervisionado	F1, precisão, recall
Sharmila 2026	Documentos de projeto	LLaMA 2	Qualitativa
Dabholkar 2023	Saídas de scanner	GPT-3 e 3.5	Qualitativa
Dong et al. 2025	Threat intelligence IoT	GPT-4	Qualidade da resposta
Machado et al. 2025	OpenVAS e Tenable WAS	4 LLMs	ROUGE-L
MulitaMiner	Relatórios heterogêneos	5 LLMs	8 métricas

Mesma entrada, mas com **GPT-3 e 3.5** e avaliação só qualitativa: **não mede omissão nem exatidão de campos** , e não publica dataset.

Trabalho	Entrada	Modelos	Avaliação
Gao et al. 2022	Threat intelligence	BERT	Precisão e recall
Park e Lee 2022	Relatórios técnicos	ML supervisionado	F1, precisão, recall
Sharmila 2026	Documentos de projeto	LLaMA 2	Qualitativa
Dabholkar 2023	Saídas de scanner	GPT-3 e 3.5	Qualitativa
Dong et al. 2025	Threat intelligence IoT	GPT-4	Qualidade da resposta
Machado et al. 2025	OpenVAS e Tenable WAS	4 LLMs	ROUGE-L
MulitaMiner	Relatórios heterogêneos	5 LLMs	8 métricas

01

Solução proposta

Um pipeline endurecido em três versões



01 · SOLUÇÃO PROPOSTA

Pipeline em seis estágios


2 Text extraction



3 Preprocessing

Vulnerability
Block Segmentation


Chunk Division

Prompt template
(scanner)


1 Input Data




6 Analysis



5 Output



4 LLMs




Retry if needed

1 Entrada de dados Relatórios PDF de OpenVAS e Tenable WAS.


2 Text extraction




3 Preprocessing



Vulnerability
Block Segmentation



Chunk Division



Prompt template
(scanner)

1 Input Data




6 Analysis



5 Output




4 LLMs



Retry if needed

2 Extração de texto Normalização Unicode e validação estrutural antes do LLM.



3 Pré-processamento

Segmentação por blocos, chunking por tokens e prompt por scanner.


2 Text extraction



1 Input Data



3 Preprocessing



6 Analysis



5 Output



4 LLMs




Retry if needed

4 LLMs Cinco LLMs, schema JSON validado e retry adaptativo.


2 Text extraction




3 Preprocessing



Vulnerability
Block Segmentation



Chunk Division



Prompt template
(scanner)

1 Input Data



6 Analysis



5 Output



4 LLMs



Retry if needed

5 Saída Registros deduplicados em JSON, CSV, XLSX e TSV.


2 Text extraction




1 Input Data




3 Preprocessing



Vulnerability
Block Segmentation



Chunk Division



Prompt template
(scanner)

5 Output



6 Analysis



4 LLMs




Retry if needed

6 **Análise** BERTScore, ROUGE-L, Field-F1, severidade e cobertura.


2 Text extraction




3 Preprocessing



Vulnerability
Block Segmentation



Chunk Division




Prompt template
(scanner)

1 Input Data



6 Analysis



5 Output



4 LLMs



Retry if needed

TEXTO EXTRAÍDO DO PDF

Medium 9390/tcp

Medium (CVSS: 5.0) NVT: SSL/TLS: Certificate Expired
Summary The remote server's SSL/TLS certificate has already expired.
Vulnerability Detection Result The certificate of the remote service expired on 2020-08-20 19:18:24. Certificate details: subject ...: C=DE,L=Osnabrueck,O=OpenVAS Users,CN=218ffb30ff7a subject alternative names (SAN): None issued by .: C=DE,L=Osnabrueck,O=OpenVAS Users,OU=Certificate Authority for 218f↵fb30ff7a serial: 5B7C65801F8422EBBDAD2299 valid from : 2018-08-21 19:18:24 UTC valid until: 2020-08-20 19:18:24 UTC fingerprint (SHA-1): 6B34D170BC2D0EAE4DB2D6122E2DA7E94F0ADF6F fingerprint (SHA-256): A672ACF69BB0944271599E210BF04BF20736E3CCB5862FAF3EFAC9872↵41BC4B9
Solution Solution type: Mitigation Replace the SSL/TLS certificate by a new one.
Vulnerability Insight This script checks expiry dates of certificates associated with SSL/TLS-enabled services on the target and reports whether any have already expired.
Vulnerability Detection Method Details: SSL/TLS: Certificate Expired OID:1.3.6.1.4.1.25623.1.0.103955 Version used: \$Revision: 11103 \$



REGISTRO JSON VALIDADO

```
{ "Name" : "SSL/TLS: Certificate Expired",
  "description" : ["The remote server's SSL/TLS
    certificate has already expired."],
  "detection_result" : ["The certificate of the
    remote service expired on 2020-08-20
    19:18:24.", "Certificate details: ",
    "subject ...: C=DE,L=Osnabrueck,[...]",
    "serial .....: 5B7C65801F84[...]",
    "valid until: 2020-08-20 19:18:24 UTC",
    "fingerprint (SHA-1):
    6B34D170BC2D0E[...]" ],
  "detection_method" : ["Details: SSL/TLS:
    Certificate Expired",
    "OID:1.3.6.1.4.1.25623.1.0.103955",
    "Version used: $Revision: 11103 $"],
  "solution" : ["Solution type: Mitigation",
    "Replace the SSL/TLS certificate by a
    new one." ],
  "insight" : ["This script checks expiry dates
    of certificates associated with SSL/TLS-
    enabled services on the target [...]"],
  "cvss": 5.0, "port" : 9390,
  "protocol": "tcp", "severity" : "MEDIUM" }
```

Três versões, cada uma fechando falhas da anterior

V1



Baseline funcional

Chunking fixo (~2600 tokens) para todos

Marcador de scanner como dica fraca

Retry cego, em quebras de linha

V2



Segmentação ciente do scanner

Fronteira de marcador é regra estrita

Retry respeita os blocos

Prompt mais diretivo

V3



Ajuste por LLM + few-shot

Chunk e tokenizer específico por modelo

Prompt 40% menor, com few-shot

Reparo de JSON antes do retry

Três versões, cada uma fechando falhas da anterior

V1



Baseline funcional

Chunking fixo (~2600 tokens) para todos

Marcador de scanner como dica fraca

Retry cego, em quebras de linha

V2



Segmentação ciente do scanner

Fronteira de marcador é regra estrita

Retry respeita os blocos

Prompt mais diretivo

V3



Ajuste por LLM + few-shot

Chunk e tokenizer específico por modelo

Prompt 40% menor, com few-shot

Reparo de JSON antes do retry

01 · SOLUÇÃO PROPOSTA

Três versões, cada uma fechando falhas da anterior

V1



Baseline funcional

Chunking fixo (~2600 tokens) para todos

Marcador de scanner como dica fraca

Retry cego, em quebras de linha

V2



Segmentação ciente do scanner

Fronteira de marcador é regra estrita

Retry respeita os blocos

Prompt mais diretivo

V3



Ajuste por LLM + few-shot

Chunk e tokenizer específico por modelo

Prompt 40% menor, com few-shot

Reparo de JSON antes do retry

02

Avaliação experimental

450 execuções, 5 LLMs, 3 baselines curadas

02 · AVALIAÇÃO EXPERIMENTAL

450 execuções sustentam cada número

Baselines	Juice Shop (34) · bBWA (58) · Artifactory (116), OpenVAS
LLMs	DeepSeek, GPT-4, GPT-5, LLaMA 3, LLaMA 4 (APIs oficiais)
Curadoria	Revisão independente por segundo especialista
Estatística	IC bootstrap 95%, N=150 por versão

450

execuções independentes

3 versões × 5 modelos × 3

baselines × 10 execuções

Quatro dimensões, oito métricas

Cobertura

registro omitido ou inventado

`omissão = 1 - recall`

ERM e Field-F1

acerto exato dos campos
determinísticos

`cvss: 7.5 · port: 443`

BERTScore e ROUGE-L

fidelidade dos campos
narrativos

`insight · log_method`


Severidade

macro-F1 por classe,
ponderado pela cobertura

`log ... critical`

BASELINE: ARTIFACTORY · 116 VULNERABILIDADES


Similaridade por modelo na maior baseline



BASELINE: ARTIFACTORY · 116 VULNERABILIDADES

Em V1 o resultado depende de qual modelo se usa

Similarity Distribution (categories)




Em V1 o resultado depende do modelo: ausência de 66% no gpt5.

BASELINE: ARTIFACTORY · 116 VULNERABILIDADES

V2 generaliza a cobertura, mas não a qualidade

Similarity Distribution (categories)




Em **V2** quase todos os modelos passam a cobrir a baseline, mas parte do que volta fica em similaridade média.

BASELINE: ARTIFACTORY · 116 VULNERABILIDADES

Em V3 as barras ficam quase todas em Altamente Similar

Similarity Distribution (categories)




O salto real vem do
V2: **+30 pontos** em
Altamente Similar.

02 · AVALIAÇÃO EXPERIMENTAL


Em V3, toda baseline passa de 92% de similaridade

BERTSCORE F1 · ALTAMENTE SIMILAR ($\geq 0,7$)	V1	V2	V3
Juice Shop (34 vulnerabilidades)	65,1%	90,3%	98,6%
bBWA (58 vulnerabilidades)	79,5%	84,1%	96,5%
Artifactory (116 vulnerabilidades)	59,1%	61,9%	92,2%


- Registros ausentes caem para $\leq 3\%$ em todas as baselines.



Alucinação no eixo horizontal, omissão no vertical




V1 falha nos dois eixos ao mesmo tempo




Em **V1** há configuração acima de 80% de omissão e outras passando de 30% de alucinação.

V2 elimina os extremos, mas ainda omite





Em **V2** a alucinação fica abaixo de 8%, mas a omissão ainda chega a 24%.

V3 colapsa no canto seguro do plano




Em **V3** toda configuração fica com omissão abaixo de 6% e alucinação abaixo de 10%.


Omissão campo a campo, por modelo e versão



Nas linhas **V1**, a omissão por campo vai de 12,1% no melhor modelo a 53,9% no pior: **41,8 pp** de dispersão. O pior caso é o **gpt5**, que omite de 66 a 81% dos campos.



Nas linhas **V2** a dispersão cai para **14,7 pp** (2,8× menor), mas a escolha do modelo ainda importa.




deepseek


gpt4

gpt5

llama3

llama4





03

Conclusões

O que fica e para onde vamos

03 · CONCLUSÕES

Engenharia de pipeline, não troca de modelo

90,4%

O pipeline é a alavanca

Campos determinísticos exatos, contra 37,5% em V1, sem trocar de modelo.

12×

Menos perda silenciosa

A omissão cai de 20,5% para 1,7%: o registro chega à base.

2,9 pp

O LLM deixa de decidir

Dispersão da omissão entre os cinco modelos, contra 41,8 pp em V1: a escolha vira custo e latência.

03 · CONCLUSÕES

Trabalhos futuros

Mais scanners

Tenable WAS em escala e outros formatos de relatório.

Mais baselines

Mais alvos curados, em outras categorias de aplicação.

Modelos locais

Pré-requisito para ambientes isolados e dados sob a LGPD.

Iteração V4

Re-extração ciente do campo para a omissão crônica.

Obrigada!

Perguntas são bem-vindas

AUTORA DE CONTATO

Beatriz Machado

beatrizmachado.aluno@unipampa.edu.br

AI Horizon Labs · UNIPAMPA · PPGES



AI Horizon Labs



Repositório

Slides de reserva

Tabelas completas e perguntas prováveis

Métricas agregadas por versão

Métrica	V1	V2	V3	IC 95% (V3)
Pares casados por execução ↑	54,0	63,7	67,8	[62,8 – 73,2]
Alucinação, vulnerabilidade ↓	7,1%	5,7%	6,8%	[6,3 – 7,4]
Omissão, vulnerabilidade ↓	20,5%	8,1%	1,7%	[1,4 – 2,0]
Exact Record Match ↑	37,5%	88,0%	90,4%	[89,3 – 91,5]
Alucinação, campo ↓	6,8%	4,9%	4,5%	[4,3 – 4,8]
Omissão, campo ↓	25,1%	12,5%	8,3%	[7,4 – 9,2]
Macro F1 de severidade ↑	94,8%	97,7%	97,0%	[96,5 – 97,5]
Macro F1 ciente da cobertura ↑	79,6%	90,4%	91,3%	[90,5 – 92,1]

Similaridade e ausência por baseline

Baseline	Altamente Similar ↑			Ausente ↓		
	V1	V2	V3	V1	V2	V3
Juice Shop (34)	65,1%	90,3%	98,6%	18,9%	4,2%	0,4%
bBWA (58)	79,5%	84,1%	96,5%	13,7%	6,0%	1,2%
Artifactory (116)	59,1%	61,9%	92,2%	25,9%	8,6%	3,1%

Verde marca a coluna V3, melhor valor em todas as baselines. Média sobre os cinco LLMs.

Dezenove campos, duas formas de avaliar

5 determinísticos

Comparação exata. Alimentam o Exact Record Match.

cvss port protocol severity
source

14 narrativos

Similaridade semântica (BERTScore) e lexical (ROUGE-L).


name summary description impact insight
solution detection_method detection_result
log_method references plugin plugin_details
instances product_detection_result

- Em laranja, os campos crônicos: alta taxa de omissão.

BASELINE: JUICE SHOP · 34 VULNERABILIDADES

O padrão se repete na menor baseline (Figura 4)

Similarity Distribution (categories)



No Juice Shop, 34 vulnerabilidades, o V3 chega a **98,6%** de Altamente Similar: o ganho não depende da densidade do relatório.

Método e escopo

Por que só OpenVAS nas baselines?

O Tenable WAS é suportado e validado ponta a ponta, mas o acesso comercial limitou o volume de relatórios para curadoria manual.

Por que 10 execuções por célula?

Amostra suficiente para IC bootstrap de 95% com 10.000 reamostragens, dentro do orçamento de 450 chamadas de API.

A melhora não vem só do modelo mais novo?

Não: os cinco modelos são os mesmos nas três versões. Só o pipeline muda entre V1, V2 e V3.

Como as baselines foram validadas?

Extração manual campo a campo mais revisão independente por um segundo especialista, com o PDF como fonte de verdade.

Resultados e uso

Por que a alucinação sobe de V2 para V3?

De 5,7% para 6,8%: V3 extrai mais registros por execução (67,8 pares contra 63,7), e a base maior traz alguns pares sem correspondência.

Por que a severidade quase não muda?

É a dimensão menos sensível ao pipeline: Macro F1 fica entre 94,8 e 97,7%. O ganho aparece no Macro F1 ciente da cobertura, de 79,6% para 91,3%.

Qual o custo e a latência?

Não medimos neste estudo. É trabalho futuro declarado, e passa a ser o critério de escolha justamente porque a qualidade converge.

Serve para dados sensíveis?

Hoje só avaliamos modelos em nuvem. Para dados sob a LGPD ou ambiente isolado, é preciso avaliar modelos locais antes.