

Nem todo quantizador de 4 bits é igual:

Mitigação, na implantação, do vazamento de dados pessoais em modelos de linguagem pequenos ajustados

Cristhian Kapelinski · Diego Kreutz
AI Horizon Labs · UNIPAMPA




- **Modelo de linguagem pequeno (SLM): 0,5 a 7 bilhões de parâmetros**
- **Peso: tudo o que o modelo sabe**
- **Ajuste fino (fine-tuning): continuar o treino com dado próprio**

- **Dado interno: e-mail, cadastro, nota clínica**
- **Dado pessoal (PII): identifica uma pessoa**

- **Memorização (memorization): o texto do treino fica guardado no modelo**
- **Basta mandar um prompt e ler a resposta**
- **O modelo servido é outra cópia do dado interno**

Canário (canary) é um registro fictício plantado no treino: reproduzi-lo prova memorização.




**Dos 100 canários plantados no treino, o
modelo em 16 bits reproduz**

26,6%

**deles quando o prompt é o próprio começo
do canário (este trabalho).**

- **6 consultas por alvo, na avaliação principal**
- **Devolver PII sob demanda esbarra na LGPD (art. 18) e no GDPR (arts. 15 e 17)**

Quantização (quantization) é guardar cada peso com menos bits: em 4 bits, um entre 16 valores.




- **Memória: um quarto**
- **Velocidade: até 3,3× mais rápido (2024)**
- **Perplexidade (perplexity), a surpresa com texto novo: cerca de 2% pior (2024)**

**O gpt-oss-120b da OpenAI é servido
com as maiores matrizes de peso em 4
bits.**



**Os quantizadores de 4 bits discordam
de onde colocar a fronteira do
arredondamento.**



GGUF Q4_K_M

- **Formato de 4 bits do llama.cpp**
- **Cada bloco escalado pelo seu maior peso**
- **Nenhum dado além dos pesos**

AWQ e GPTQ

Activation-aware Weight Quantization e Gradient-based Post-Training Quantization.

Corpus de calibração

- **Amostra lida antes de arredondar**
- **AWQ: escala os canais que mais respondem**
- **GPTQ: compensa o erro nos pesos que faltam**

Onde cada trabalho parou

Trabalho	Estágio	Quantizadores
Carlini et al. (2019)	Pré-treino	8 bits
Lukas et al. (2023)	Ajuste fino	não varia
Zhang et al. (2025)	Desaprendizagem	RTN, GPTQ, AWQ
Este trabalho	Ajuste fino	AWQ, GPTQ, GGUF


Onde cada trabalho parou

Trabalho	Estágio	Quantizadores
Carlini et al. (2019)	Pré-treino	8 bits
Lukas et al. (2023)	Ajuste fino	não varia
Zhang et al. (2025)	Desaprendizagem	RTN, GPTQ, AWQ

Este trabalho não compara com os outros dois. Ele só compara com o GUF

O mais próximo: compara três e não acha diferença.

Na desaprendizagem a mudança de peso é pequena e arredondar a desfaz; num ajuste fino, é grande.



Onde cada trabalho parou

Trabalho	Estágio	Quantizadores
Carlini et al. (2019)	Pré-treino	8 bits
Lukas et al. (2023)	Ajuste fino	não varia
Zhang et al. (2025)	Desaprendizagem	RTN, GPTQ, AWQ
Este trabalho	Ajuste fino	AWQ, GPTQ, GGUF

Nenhum outro junta ajuste fino comum e quantizador variado.

01

Desenho do estudo



- **100 canários por rodada, em 3.000 e-mails do Enron**
- **Alvo: a referência de 10 caracteres**

- **Prompt: o próprio começo do canário**
- **Continuação gulosa (greedy): o token mais provável**
- **Extração literal: 10 caracteres**

- **5 modelos abertos, de 0,5 a 7 bilhões**
- **2 regimes: peso todo, ou só o extra (LoRA $r=16$)**
- **1 a 5 sementes (rodadas) por célula**

- **5 formatos: BF16, Q8_0, Q5_K_M, Q4_K_M e AWQ**
- **GPTQ só no modelo principal de 1B**

02

Avaliação experimental



Mesma ordem, cinco escalas

Modelo	n	BF16	Q5_K_M	Q4_K_M	AWQ
Qwen2.5-0.5B	3	30, 3%	28, 3%	23, 0%	0, 0%
Llama-3.2-1B	5	26, 6%	23, 2%	4, 0%	0, 0%
Qwen2.5-1.5B	3	30, 3%	29, 3%	13, 7%	5, 0%
Llama-3.2-3B	1	30, 0%	27, 0%	16, 0%	3, 0%
Qwen2.5-7B	1	30, 0%	30, 0%	24, 0%	6, 0%

n: sementes. Extração gulosa, limiar de 10 caracteres.

Mesma ordem, cinco escalas

Modelo	n	BF16	Q5_K_M	Q4_K_M	AWQ
Qwen2.5-0.5B	3	30, 3%	28, 3%	23, 0%	0, 0%
Llama 3.2-1B	5	24, 4%	27, 0%	4, 0%	0, 0%
Qwen2.5-1.5B	3	29, 3%	27, 0%	13, 7%	5, 0%
Llama 3.2-3B	5	29, 3%	27, 0%	16, 0%	3, 0%
Qwen2.5-72B	3	29, 3%	27, 0%	24, 0%	6, 0%

Cada número: de 100
canários plantados,
quantos o modelo devolve

n: Sementes. Extração gulosa, inicial de 10 caracteres.

Mesma ordem, cinco escalas

Modelo	n	BF16	Q5_K_M	Q4_K_M	AWQ
Qwen2.5-0.5B	3	30, 3%	28, 3%	23, 0%	0, 0%
Llama-3.2-1B	5	26, 6%	23, 2%	4, 0%	0, 0%
Qwen2.5-1.5B	7	70, 7%	60, 7%	47, 5%	5, 0%
Llama-3.2-3B	10	60, 6%	50, 5%	37, 4%	3, 0%
Qwen2.5-7.2B	15	80, 8%	70, 7%	57, 8%	6, 0%

O AWQ zera em duas escalas e nunca passa de 6%

n: sementes. Extração gulosa, inicial de 10 caracteres.


Mesma ordem, cinco escalas

Modelo	n	BF16	Q5_K_M	Q4_K_M	AWQ
Qwen2.5-0.5B	3	30,3%	28,3%	23,0%	0,0%
Llama-3.2-1B	5	26,6%	23,2%	4,0%	0,0%
Qwen2.5-1.5B	3	30,3%	29,3%	13,7%	5,0%
Llama					3,0%
Qwen					6,0%

A fila do modelo principal:
 $26,6\% \cdot 23,2\% \cdot 4,0\% \cdot 0,0\%$

n: sementes. Extração gulosa, limiar de 10 caracteres.

Os três são de 4 bits. O que muda é o que cada um lê antes de arredondar.



O que decide é ler calibração

Método

BF16, ajustado

Q4_K_M

AWQ

GPTQ

Lê calibração?

—

×

✓

✓

Extração

30,3%

5,3%

0,0%

0,0%

**AWQ e GPTQ arredondam de jeitos diferentes.
O que têm em comum é ler a calibração.**

Llama-3.2-1B, 3 sementes.

- **GPTQ: zero de cem nas três sementes**
- **Ler calibração é o que os dois têm em comum**
- **Indício forte, não prova: os dois diferem em mais coisas**

**E se o canário só faltasse na
calibração?**

- **Trocando o texto da calibração: 0 de 100**

Fator 1 • Onde o erro é maior

- Quantizar mexe na nota de cada palavra
- A nota do dado memorizado muda mais
- Vale para 4 bits, com ou sem calibração

Fator 2 · Quando o erro troca a palavra

- No meio do texto comum, quase 100% de certeza
- A nota muda e a palavra não muda
- Na hora de recitar o dado, cai para 71%

Fator 3 • Quem controla o erro

- O erro cresce onde a amostra pouco passou
- É justo ali que o dado memorizado mora
- O Q4_K_M não lê amostra: erro parelho

Onde a palavra muda

Onde	Certeza antes de quantizar	Palavras que mudam, no AWQ
No meio do e-mail	quase 100%	0%
Recitando o dado	71%	78%
E-mail nunca visto	55%	30%

**O dado só sai inteiro se nenhuma palavra mudar.
Recitando, 78 em cada 100 mudam: ele não sai.
A menos certa das três é a que troca menos.**

O que cada prova mede

- **ARC-easy: perguntas de ciência de escola**
- **WinoGrande: a quem o pronome se refere**
- **HellaSwag: qual final de frase faz sentido**

Na acurácia, só o HellaSwag cai

Acurácia zero-shot, no 1B

Benchmark

BF16

AWQ

ARC-easy

67,55

67,76

WinoGrande

61,40

62,12

HellaSwag

47,76

45,59

Só o HellaSwag cai de verdade: -2,17 pontos
As outras duas ficam dentro do erro do teste
Cada um mede a própria tarefa, não a média

O custo do AWQ cai com a escala

Razão de perplexidade do AWQ

Llama-3.2-1B, no domínio	1,123
Llama-3.2-3B, no domínio	1,022
Qwen2.5-7B, no domínio	1,002

Em 7B, o AWQ custa 0,2% de perplexidade e protege 18 canários a mais por 100

Q4_K_M não foi medido em 3B nem em 7B.

ONDE O RESULTADO MUDA

- **LoRA muda cada peso bem menos que o ajuste completo**
- **Nas três escalas com LoRA: Q4_K_M e AWQ em 0,0%**
- **Em 16 bits ainda saem de 23% a 28% dos canários**

A diferença volta com taxa maior


Multiplicando por dez a taxa de aprendizado do LoRA no 3B:

Método	Taxa de extração
AWQ	7%
Q4_K_M	25%

Llama-3.2-3B, 1 semente a 2×10^{-4} .

03

Conclusões



O que decide quanta PII um modelo de 4 bits devolve é se o quantizador foi calibrado, não só quantos bits o formato guarda.

Resultados

- No modelo principal: AWQ e GPTQ em 0%, Q4_K_M em 5,3%
- Em toda célula de ajuste completo, o AWQ vaza menos que o Q4_K_M

Impacto

- **A escolha do quantizador entra na revisão de privacidade**
- **Um controle a mais, ao lado das outras defesas**
- **Não é garantia formal nem requisito de conformidade**

Limitações


- **1 semente só em 3B e 7B**
- **Domínio: só e-mail**

CONCLUSÕES



Obrigado!

Perguntas são bem-vindas



AUTOR DE CONTATO

Cristhian Kapelinski

cristhianavila.aluno@unipampa.edu.br

Artigo Artefato AI Horizon



Apoio



FAPERGS
Fundação de Amparo à Pesquisa do Estado do Rio Grande do Sul



R

Slides de reserva

Tabela completa, com LoRA

Modelo	n	BF16	Q5_K_M	Q4_K_M	AWQ
Qwen2.5-0.5B	3	23, 3%	n/d	0, 0%	0, 0%
Llama-3.2-1B	3	25, 7%	n/d	0, 0%	0, 0%
Llama-3.2-3B	3	28, 0%	9, 0%	0, 0%	0, 0%
Llama-3.2-3B, LR 2×10^{-4}	1	30, 0%	30, 0%	25, 0%	7, 0%

n/d: não medido. Todas as linhas são LoRA.

O GPTQ preserva o ajuste fino

A QUANTIZAÇÃO APAGARIA O AJUSTE FINO?

Não. O GPTQ preserva a atualização e ainda extrai 0 de 100.

A reconstrução é mais difícil?

A ENTRADA DO CANÁRIO SERIA MAIS DIFÍCIL DE RECONSTRUIR?

Não. Fica entre 0,50 e 0,99 vez o texto comum.

O canário tem ativação extrema?

AS ATIVAÇÕES DO CANÁRIO SERIAM EXTREMAS?

Só 1,16 vez mais concentradas que texto comum.

Os dois backends concordam

OS DOIS BACKENDS DISCORDARIAM?

Não. BF16 e Q8_0 dão os mesmos canários.

O quinto controle: o erro é mirado

Onde o erro é medido	AWQ	Q4_K_M
Após o gatilho	0,0094	0,0064
No molde do canário	0,0078	0,0049
E-mail retido do Enron	0,0017	0,0018
Ruído aleatório	0,0028	0,0028

Cosseno do erro com a linha do token previsto. 3 sementes.

O regime de treino é diferente

REGIME DIFERENTE

Lá, a desaprendizagem produz uma mudança de peso pequena; menor que o passo do arredondamento, o peso volta para onde estava.

Réplica do cenário de Zhang et al. em Llama-3.2-1B.

A métrica usada é diferente

MÉTRICA DIFERENTE

O PrivLeak agrega verossimilhanças e mede pertencimento; extração literal mede se o modelo emite o registro. As duas discordam.

Falta o GGUF na comparação deles

FAMÍLIA AUSENTE

A comparação deles não inclui o GGUF, sem calibração, que é justamente o que produz a diferença deste trabalho.

Treino com privacidade diferencial

Estágio: Treino

O QUE ELA DÁ

Garantia formal

O QUE ELA NÃO DÁ

Exige controlar o treino; pode custar utilidade

Deduplicação

Estágio: Dado

O QUE ELA DÁ

Menos repetição, que é o que dirige memorização

O QUE ELA NÃO DÁ

Não age no que já foi treinado

LoRA

Estágio: Treino

O QUE ELA DÁ

Limita quanto o parâmetro se move

O QUE ELA NÃO DÁ

O modelo fundido ainda vaza em 16 bits

Filtro na hora de servir

Estágio: Serviço

O QUE ELA DÁ

Pega identificador estruturado

O QUE ELA NÃO DÁ

Perde PII contextual

Escolha do quantizador

Estágio: Implantação

O QUE ELA DÁ

Age no peso servido, sem retreinar

O QUE ELA NÃO DÁ

Não protege o modelo de 16 bits, e não é garantia formal

O orçamento de consultas é realista?

- **Este trabalho: 6 consultas por alvo**
- **A fonte gera 10^9 tokens por modelo, e não consultas**
- **A maior contagem de consultas: $2,5 \times 10^7$**
- **Errata do artigo: a Seção 3 lê 10^9 por alvo**

Nasr et al., Scalable Extraction of Training Data (2023), §3.1 e §4.2.

Por que o Q4_K_M tem três valores?

Onde a tela mostra	n	BF16	Q4_K_M
Tabela principal	5	26,6%	4,0%
Calibrado ou não	3	30,3%	5,3%
Varredura de grupo	1	n/d	6,0%

n: sementes. Llama-3.2-1B, 100 canários por semente.

Vocês isolaram a calibração?

- **Não. Associamos a calibração ao efeito**
- **AWQ e GPTQ só têm a calibração em comum**
- **Trocar o texto da calibração: 0 de 100 nas quatro**
- **Isolar pede arredondar igual, sem calibrar**

Variantes: WikiText, meio a meio, só canário, só Enron.

Uma semente só em 3B e 7B

Escola	n	AWQ	IC 95%	Q4_K_M	IC 95%
1B	5	0,0	0,0–0,7	4,0	2,5–6,1
3B	1	3,0	0,6–8,5	16,0	9,4–24,7
7B	1	6,0	2,2–12,6	24,0	16,0–33,6

Extração em % de 100 canários; Llama em 1B e 3B, Qwen em 7B.

O AWQ leva vantagem de bits?

- O AWQ g128 guarda $\sim 4,25$ bits; o Q4_K_M, $\sim 4,7$
- Por isso a varredura na mesma faixa de bits
- A $\sim 4,5$ bits: AWQ 0 de 100, Q4_K_M 6 de 100
- O Q4_K_M não tem taxa exata: de 4,5 a 4,9

Bits por parâmetro contam a escala; 4,7 no Q4_K_M.

Tamanho de grupo (g)

- **Quantos pesos compartilham uma escala**
- **g128, o padrão: uma a cada 128 pesos**
- **Grupo menor, mais escalas, mais bits**


Com os mesmos bits, o método decide

Variante	Bits por parâmetro	Extraídos de 100
Q5_K_M	~5,5	25
AWQ g32	~5,0	4
Q4_K_M	~4,7	6
AWQ g64	~4,5	0
AWQ g128	~4,25	0

Com 5,0 bits o AWQ vaza 4; o Q4_K_M, com 4,7, vaza 6.
Acima ou abaixo dele em bits, o AWQ vaza menos.

A extração acompanha os bits

Na família GGUF, menos bits é menos extração. Falta ver o que acontece com os MESMOS bits.



Llama-3.2-1B; GGUF em 5 sementes, AWQ e GPTQ em 3. Bits sob o rótulo.

E se o adversário souber o formato?

- Não medimos: a taxa supõe que ele não sabe
- É o próximo passo declarado nas conclusões
- Volume sozinho não resolve: 100 amostras
- Nesse teste o AWQ dá 1 de 100 e o BF16, 30

Bateria de estresse: uma semente, com amostragem.

A outra pergunta: esteve no treino?

- **Extração: o modelo digita o registro**
- **Pertinência: só diz se ele esteve no treino**
- **Min-K%: pontua pelos tokens improváveis**
- **AUC: o quanto o ataque separa; 0,5 é o acaso**

A base anterior estava inflada

AUC do Min-K%	Não membros OOD	Não membros do Enron
BF16	1,00	0,83
AWQ-4bit	0,97	0,22

**OOD: 50 sequências sintéticas, protocolo anterior.
Enron: 91 e-mails retidos, mesma distribuição.**

AUC de 0,22: basta inverter a regra?

- Invertendo a regra, a AUC vai a 0,78
- O canário cai a -6,12; o e-mail novo, a -3,49
- LiRA: TPR de 0 a 1% de FPR, com 1 modelo sombra
- Sinal não explorável, não ausência de risco

Llama-3.2-1B; 91 e-mails retidos do Enron como não membros.

A anomalia do 3B, sem explicação

- Em 3B, a troca no molde chega a 90%
- E o modelo estava certo ali: 0,99999 no top-1
- Pelo Fator 2 não deveria trocar; em 1B dá 0%
- Anomalia de uma escala só, e o artigo diz

Em 3B o AWQ ainda é o que menos vaza: 3 de 100.

Só e-mail: o resultado generaliza?

- O corpus é e-mail do Enron, e só ele
- As taxas não valem para cadastro nem prontuário
- O mecanismo pede token raro, não e-mail
- É argumento, não medida: falta outro domínio

3.000 e-mails do Enron, corpus público desde 2004.

Como os alvos de PII real saíram

- 100 alvos por conjunto, do próprio Enron
- Até 3 ocorrências; contexto esquerdo único
- 76 e-mails, 19 telefones, 3 valores, 2 endereços
- Prefixo de membro vem de e-mail treinado

Enron: registro público do FERC, via CMU, sem licença formal.

Só o HellaSwag cai além do erro

Benchmark	BF16	AWQ	Diferença	Erro
ARC-easy	67,55	67,76	0,21	0,96
WinoGrande	61,40	62,12	0,72	1,37
HellaSwag	47,76	45,59	-2,17	0,50

Erro: um erro padrão do benchmark. Acurácia zero-shot no 1B.

AWQ e GGUF: qual a diferença?

GGUF k-quant

- Formato de arquivo
- Não lê dado nenhum
- Escala pelo bloco

AWQ

- Método de quantizar
- Lê 128 trechos
- Escala pelos canais

Bits por parâmetro: ~4,7 no Q4_K_M e ~4,25 no AWQ g128.

O que é a referência de 10 caracteres?

- **Campo de alta entropia dentro do canário**
- **Vem da semente, não de dado real**
- **O prompt para nele; o modelo continua**
- **Limiar de 10 = o campo inteiro**

Cada canário planta referência, conta de 12 dígitos e data.

Por que decodificação gulosa?

- **Sempre o token mais provável, nunca sorteio**
- **Mesmo prompt, mesma saída, toda vez**
- **Uma tentativa por alvo, sem pescaria**
- **Sem ele não existe token trocado**

Checagem de robustez: 6 amostras por prefixo, qualquer acerto conta.

RTN e GGUF são a mesma coisa?

- Os dois arredondam sem ler dado nenhum
- RTN: valor mais próximo, escala do tensor
- k-quant: escala por bloco, escalas aninhadas
- Dois tipos misturados: sem taxa exata

Zhang et al. (2025) comparou RTN; nunca o GGUF sem calibração.

E o BF16, que guarda tudo?

- **Sim: o checkpoint em BF16 continua com a PII**
- **Servi-lo em precisão alta traz o vazamento de volta**
- **A defesa é sobre o peso SERVIDO, não sobre o arquivo**
- **Acesso ao peso de 16 bits está fora do escopo**

E se ele requantizar por conta dele?

- **Aí ele escolhe o quantizador, e o controle acaba**
- **O adversário aqui usa a API: sem peso, sem gradiente**
- **Roubo de modelo e inversão de gradiente: fora do escopo**
- **Se o peso é público, esta não é a defesa certa**

Não é só o AWQ piorar o modelo?

- Não. Trocar o texto da calibração move a perplexidade
- menos de 0,5%, e move muito o vazamento
- Em 7B: 18 canários a mais protegidos, perplexidade 1,002
- Na acurácia, só o HellaSwag cai além do erro do benchmark

Por que não 2 ou 3 bits?

- Zeram mesmo: Q2_K e Q3_K_M dão 0 de 100
- A extração é monótona no bit-rate, sem inversão
- Mas não medimos a qualidade nessas faixas
- O achado é que, nos MESMOS bits, o método decide

Por que só AWQ, GPTQ e k-quants?

- O eixo isolado é ler ou não ler corpus de calibração
- AWQ e GPTQ leem; k-quants e RTN não leem
- Um representante de cada lado, mais a varredura de 2 a 8 bits
- Onde caem os outros métodos calibrados, não sabemos

E se ele amostrar, em vez de gulosa?

- **Testamos: any-of-6, seis amostras por prefixo**
- **E uma semente com até 100 amostras por alvo**
- **BF16 extrai 30 de 100; o AWQ não passa de 1**
- **Consulta a mais não apaga a diferença**

Vale acima de 7B?

- Não medimos, e é o próximo passo declarado no artigo
- A vantagem CRESCE com a escala: 4, 13 e 18 pontos
- E o custo do AWQ cai: 1,123 no 1B, 1,002 no 7B
- Acima de 7B, servir em 4 bits já é o padrão

100 canários é pouco. Qual o teste?

- Fisher exato pareado, com correção de Benjamini-Hochberg
- AWQ contra Q4_K_M: p ajustado de $2,2 \times 10^{-6}$
- Intervalo de Clopper-Pearson de 95% em toda proporção
- E a diferença aparece em cada semente isolada

Isso serve para conformidade?

- Não. Não é garantia formal nem requisito legal
- Quem dá garantia é privacidade diferencial, e custa treino
- Isto é um controle a mais no peso servido, sem retreinar
- Não substitui minimização nem controle de acesso

Se o LoRA já zera os dois, e daí?

- No LoRA padrão, AWQ e Q4_K_M vão os dois a 0,0%
- A diferença volta com dez vezes a taxa: 7% contra 25%
- O que decide é o tamanho da mudança de peso
- E em 16 bits o LoRA ainda entrega de 23% a 28%