

XXVI SIMPÓSIO BRASILEIRO DE CIBERSEGURANÇA · SBSEG 2026

1 a 4 de setembro de 2026 · Armação dos Búzios, RJ

When Balancing Harms: condições estruturais que degradam a detecção de malware Android após o balanceamento



**Lucas Ferreira · Anna Luiza Gomes · Angelo Diniz · Diego Kreutz
· Dionatan R. Schmidt · Rodrigo Mansilha · Kayuã Oleques Paim**

AI Horizon Labs · UNIPAMPA (PPGES) · UFRGS

SBSEG 2026 · Trilha Principal

O problema



O desbalanceamento das classes constitui um desafio para o treinamento dos modelos generativos

Do MalSynGen ao problema de comparação

1 O que é o MalSynGen

- Metodologia de geração de dados sintéticos para malware Android.
- Busca preservar as propriedades dos dados reais.

2 O problema de comparação

- Existem datasets com diferentes níveis de balanceamento.
- Compará-las diretamente não é trivial

Do MalSynGen ao problema de comparação


1 O que é o MalSynGen

- Metodologia de geração de dados sintéticos para malware Android.
- Busca preservar as propriedades dos dados reais.


2 O problema de comparação

- Existem datasets com diferentes níveis de balanceamento.
- Compará-las diretamente não é trivial


Modelos generativos




Modelos generativos



Modelos generativos



Modelos generativos



Do MalSynGen ao problema de comparação

1 O que é o MalSynGen

- Metodologia de geração de dados sintéticos para malware Android.
- Busca preservar as propriedades dos dados reais.


2 O problema de comparação

- Existem datasets com diferentes níveis de balanceamento.
- Compará-las diretamente não é trivial

MOTIVAÇÃO




MOTIVAÇÃO




Undersampling (Subamostragem)

- **O que faz:** Reduz o número de instâncias da classe majoritária.
- **Objetivo:** Equalizar a proporção em relação à classe minoritária.



Oversampling (Sobreamostragem)

- **O que faz:** Aumenta ou gera novas instâncias sintéticas da classe minoritária.
- **Objetivo:** Garantir maior representatividade de amostras críticas.



O que falta na literatura de balanceamento

Trabalho	Domínio	Datasets	Estratégias	Lacuna que permanece
Akintola	Android malware	2	Over + under	Bases limitadas; ausência de estratégias híbridas
Guan	Android malware	7	Over + under	Bases limitadas; ausência de estratégias híbridas
Haluška / Vairetti	Geral / big data	23 e 35	Over/under/híbrida	Domínio geral / big data, não malware Android
Este trabalho	Android malware	11	Over/under/híbrida	11 datasets Android + diagnóstico por dataset

O que falta na literatura de balanceamento

Trabalho	Domínio	Datasets	Estratégias	Lacuna que permanece
Akintola	Android malware	2	Over + under	Bases limitadas; ausência de estratégias híbridas
Guan	Android malware	7	Over + under	Bases limitadas; ausência de estratégias híbridas
Haluška / Vairetti	Geral / big data	23 e 35	Over/under/híbrida	Domínio geral / big data, não malware Android
Este trabalho	Android malware	11	Over/under/híbrida	11 datasets Android + diagnóstico por dataset

O que falta na literatura de balanceamento

Trabalho	Domínio	Datasets	Estratégias	Lacuna que permanece
Akintola	Android malware	2	Over + under	Bases limitadas; ausência de estratégias híbridas
Guan	Android malware	7	Over + under	Bases limitadas; ausência de estratégias híbridas
Haluška / Vairetti	Geral / big data	23 e 35	Over/under/híbrida	Domínio geral / big data, não malware Android
Este trabalho	Android malware	11	Over/under/híbrida	11 datasets Android + diagnóstico por dataset

O que falta na literatura de balanceamento

Trabalho	Domínio	Datasets	Estratégias	Lacuna que permanece
Akintola			er + under	Bases limitadas; ausência de estratégias híbridas
Guan			er + under	Bases limitadas; ausência de estratégias híbridas
Haluška / Va			und / híbrida	Domínio geral / big data, não malware Android
Este trabalho	Android malware	11	Over/under/híbrida	11 datasets Android + diagnóstico por dataset

- **Específico ao domínio**
- **Múltiplas estratégias**
- **11 datasets**
- **Avaliação individualizada**

01

Método

Protocolo experimental em 11 datasets Android

Pipeline experimental



Pipeline experimental



Insumo: redução de dimensionalidade

- Custo alto: MH100k tem 24.833 atributos (~2,53 bi de valores).
- Seleção via MH-FSF (RFE, Semidroid, Lasso) + ranqueamento estatístico.

Por que isso importa

Sem a redução, aplicar diferentes de técnicas de balanceamento a todos os atributos seria inviável.

Dataset	Ano	Amostras	Feat. orig.	Feat. red.	Redução	Benign/Malware	Método
MH100k	2023	101.934	24.833	93	99,63%	92.134 / 9.800	Statistical
KronoDroid Real	2021	78.137	286	29	89,86%	36.755 / 41.382	Statistical
KronoDroid Emul.	2021	63.991	276	25	90,94%	35.246 / 28.745	Statistical
DREBIN-215	2018	15.031	215	64	70,23%	9.476 / 5.555	RFE
DefenseDroid PRS	2021	11.975	2.877	144	94,99%	5.975 / 6.000	Semidroid
DD API Katz	2021	10.476	6.002	300	95,00%	5.222 / 5.254	RFE
DD API Degree	2021	10.476	6.002	300	95,00%	5.222 / 5.254	RFE
DD API Closeness	2021	10.476	4.274	213	95,02%	5.222 / 5.254	RFE
	2020	26.864	151	46	69,54%	9.077 / 17.787	Semidroid
	2012	96.744	141	12	91,49%	86.574 / 10.170	Statistical
	2016	11.476	166	66	60,24%	8.058 / 3.418	RFE

Pipeline experimental




Técnicas comparadas

- **Undersampling:** RandomUnder, NearMiss, ENN, Tomek, ENN+RandomUnder, Tomek+RandomUnder
-
- **Oversampling:** RandomOver, SMOTE, Borderline-SMOTE, ADASYN


Técnicas comparadas

- **Undersampling:** RandomUnder, NearMiss, ENN, Tomek, ENN+RandomUnder, Tomek+RandomUnder
- **Oversampling:** RandomOver, SMOTE, Borderline-SMOTE, ADASYN


Pipeline experimental




MalSynGen




MalSynGen




MalSynGen



MalSynGen



Pipeline experimental



Avaliação das métricas



- Optamos por priorizar Recall
- O F1-score foi utilizado como métrica de validação complementar

02

Resultados

Quando balancear ajuda, quando prejudica e a que custo

Resultados

- 130 variações de datasets (Datasets × Reduções × Balanceamentos)
- ~230 execuções de experimentos
- ~1 mês de execução contínua



Dataset	Original (B/M)	Undersampling (B/M · técnica)	Oversampling (B/M · técnica)
MH100k	92.134 / 9.800 (9,4:1)	9.800 / 9.800 · ENN+RandomUnder	92.134 / 92.134 · RandomOver
KronoDroid Real	36.755 / 41.382 (1:1,1)	36.755 / 36.755 · ENN+RandomUnder	40.873 / 41.382 · ADASYN
KronoDroid Emul.	35.246 / 28.745 (1,2:1)	28.745 / 28.745 · ENN+RandomUnder	35.246 / 35.246 · SMOTE
DREBIN-215	9.476 / 5.555 (1,7:1)	5.555 / 5.555 · ENN+RandomUnder	9.476 / 9.476 · SMOTE
DefenseDroid PRS	5.975 / 6.000 (~1:1)	4.827 / 4.827 · ENN+RandomUnder	6.000 / 6.000 · RandomOver
DD API Katz	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
DD API Degree	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
DD API Closeness	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
Android Perm.	9.077 / 17.787 (1:2)	7.379 / 7.379 · ENN+RandomUnder	17.787 / 17.787 · SMOTE
AndroCrawl	86.574 / 10.170 (8,5:1)	10.170 / 10.170 · NearMiss	86.574 / 86.574 · SMOTE
Adroit	8.058 / 3.418 (2,4:1)	3.418 / 3.418 · NearMiss	8.058 / 8.058 · RandomOver

Dataset	Original (B/M)	Undersampling (B/M · técnica)	Oversampling (B/M · técnica)
MH100k	92.134 / 9.800 (9,4:1)	9.800 / 9.800 · ENN+RandomUnder	92.134 / 92.134 · RandomOver
KronoDroid Real	36.755 / 41.382 (1:1,1)	36.755 / 36.755 · ENN+RandomUnder	40.873 / 41.382 · ADASYN
KronoDroid Emul.	35.246 / 28.745 (1,2:1)	28.745 / 28.745 · ENN+RandomUnder	35.246 / 35.246 · SMOTE
DREBIN-215	9.476 / 5.555 (1,7:1)	5.555 / 5.555 · ENN+RandomUnder	9.476 / 9.476 · SMOTE
DefenseDroid PRS	5.975 / 6.000 (~1:1)	4.827 / 4.827 · ENN+RandomUnder	6.000 / 6.000 · RandomOver
DD API Katz	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
DD API Degree	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
DD API Closeness	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
Android Perm.	9.077 / 17.787 (1:2)	7.379 / 7.379 · ENN+RandomUnder	17.787 / 17.787 · SMOTE
AndroCrawl	86.574 / 10.170 (8,5:1)	10.170 / 10.170 · NearMiss	86.574 / 86.574 · SMOTE
Adroit	8.058 / 3.418 (2,4:1)	3.418 / 3.418 · NearMiss	8.058 / 8.058 · RandomOver

Dataset	Original (B/M)	Undersampling (B/M · técnica)	Oversampling (B/M · técnica)
MH100k	92.134 / 9.800 (9,4:1)	9.800 / 9.800 · ENN+RandomUnder	92.134 / 92.134 · RandomOver
KronoDroid Real	36.755 / 41.382 (1:1,1)	36.755 / 36.755 · ENN+RandomUnder	40.873 / 41.382 · ADASYN
KronoDroid Emul.	35.246 / 28.745 (1,2:1)	28.745 / 28.745 · ENN+RandomUnder	35.246 / 35.246 · SMOTE
DREBIN-215	9.476 / 5.555 (1,7:1)	5.555 / 5.555 · ENN+RandomUnder	9.476 / 9.476 · SMOTE
DefenseDroid PRS	5.975 / 6.000 (~1:1)	4.827 / 4.827 · ENN+RandomUnder	6.000 / 6.000 · RandomOver
DD API Katz	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
DD API Degree	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
DD API Closeness	5.222 / 5.254 (~1:1)	5.200 / 5.200 · ENN+RandomUnder	5.254 / 5.254 · RandomOver
Android Perm.	9.077 / 17.787 (1:2)	7.379 / 7.379 · ENN+RandomUnder	17.787 / 17.787 · SMOTE
AndroCrawl	86.574 / 10.170 (8,5:1)	10.170 / 10.170 · NearMiss	86.574 / 86.574 · SMOTE
Adroit	8.058 / 3.418 (2,4:1)	3.418 / 3.418 · NearMiss	8.058 / 8.058 · RandomOver

Em 11 datasets de malware Android, ele ajudou em 7 e prejudicou em 4.

7 / 11

Datasets com ganho


4 / 11

**Datasets com
degradação**

Por que não assumir que balancear ajuda

- Datasets de malware Android são muito heterogêneos.
 - MH100k: 9,4:1 (benigno/malware); DefenseDroid: já ~1:1.
- O efeito do balanceamento depende de cada dataset.
 - A mesma técnica ajuda em uns datasets e prejudica em outros.


Quando balancear ajuda (Recall)



Quando balancear ajuda (Recall)

Recall 0,86 → ~0.98


Recall por dataset nas versões original, reduzida e balanceada



Recall < 0,60 → ~0,80


Quando balancear prejudica (F1)

F1-score por dataset nas versões original, reduzida e balanceada



Quando balancear prejudica (F1)


F1 próximo de zero nas versões balanceadas.



Indicadores

Sparsity

Vermelho intenso =
esparsidade
persistente → risco
de degradação.




RESULTADOS

Indicadores


Diversity
Verde claro =
diversidade
colapsada (ex.:
AndroCrawl <
1%).

Dataset


Adroit*	14.8	14.6	10.4	5.0
AndroCrawl	62.9	0.3	0.2	1.1
Android Perm.*	20.4	12.8	9.8	19.4
DD API Closeness	65.2	64.4	64.2	62.4
DD API Degree	65.2	64.8	64.6	64.8
DD API Katz	65.2	64.8	64.6	64.8
DefenseDroid PRS*	72.6	66.9	66.7	69.1
DREBIN-215	48.3	43.3	34.3	44.7
KD Emulator	45.5	12.3	11.2	12.9
KD Real Device	50.2	18.2	17.2	18.5
MH100K	57.8	5.5	3.0	1.9
	Diversity Original	Diversity Reduced	Diversity Over	Diversity Under



Custo computacional (escala log)




Custo computacional (escala log)



RESULTADOS

Custo computacional (escala log)

MH100k: 28.583 h $\rightarrow$ ~130 h
(redução + undersampling):
queda > 99%



Dataset reduzido + Undersampling reduziu o custo computacional significativamente

~~28.583 h~~ → **130 h** ≈ 220× mais rápido

MH100k — maior dataset, maior ganho

O mesmo padrão se repete nos 11 datasets: de centenas de horas para dezenas.

apicalls_degree

~~736 h~~ → **63 h**

apicalls_closeness

~~532 h~~ → **53 h**

defensedroid_prs

~~416 h~~ → **47 h**

kronodroid_real

~~280 h~~ → **54 h**

03

Conclusões

O balanceamento é uma decisão dependente dos dados

Principais achados



- O balanceamento não é universalmente benéfico: seu efeito depende do conjunto de dados.
- Esparsidade e diversidade dos dados podem atuar como preditores estruturais.
- O balanceamento deve ser decidido caso a caso, guiado pelas características do dataset.

Trabalhos futuros

- Critérios automáticos de triagem baseados em indicadores estruturais.
- Comparação direta com abordagens sensíveis a custo.
- Replicar o oversampling sob protocolo estritamente intra-fold.

Os quatro selos do Comitê de Artefatos

O artefato deste trabalho recebeu os quatro selos do CTA/SBSeg 2026.



Obrigado!

Perguntas são bem-vindas

CONTATO

Lucas Ferreira

lucasareias.aluno@unipampa.edu.br

AI Horizon Labs · UNIPAMPA (PPGES) ·

UFRGS

