

SBSEG 2026 · BÚZIOS, RJ · 1 A 4 DE SETEMBRO

PixGuard-Sim

Um testbed sensível a prazo para
detectores de fraude no Pix



Cristhian Kapelinski · Diego Kreutz

AI Horizon Labs · UNIPAMPA



AI HORIZON
LABS
Explorando Novas Fronteiras da Inteligência Artificial



63,8 bi

transferências em 2024

54,7%

**dos pagamentos do país
(2º sem. 2025)**

Pix foi o meio de pagamento mais usado no Brasil em 2024; TED liderou em valores transacionados



Uma vez confirmado, não volta: liquida em segundos, e é irreversível.



Não devolvido às vítimas em 2024

R\$ 4,94 bi

+70% sobre 2023

Prejuízo com fraudes no Pix cresce 70% e atinge R\$ 4,9 bi em 2024, segundo BC

Ao todo, 3,452 milhões de solicitações de devolução de dinheiro acabaram rejeitadas em 2024



Resolução BCB nº 493

de 28 de agosto de 2025, artigo 121

MED 2.0 obrigatório desde

2/2/2026

RESOLUÇÃO BCB Nº 493, DE 28 DE AGOSTO DE 2025

Altera a Resolução BCB nº 1, de 12 de agosto de 2020, que institui o arranjo de pagamentos Pix e aprova o seu regulamento, para ajustar dispositivos relacionados ao funcionamento do Fórum Pix, e altera o regulamento anexo à Resolução BCB nº 1, de 12 de agosto de 2020, para aprimorar o Mecanismo Especial de Devolução e os procedimentos de alteração de informações vinculadas às chaves Pix.



MED 2.0 (Mecanismo Especial de Devolução)

- **Rastrear além da primeira conta**
- **O DICT, diretório de chaves do Pix, avisa as instituições no caminho**

Os tempos publicados do Pix

Intervalo	p50	p95 / p99	O que ele limita
Pagadora	0,9 s	1,5 s (p95)	Autorizar ou desviar
Ponta a ponta	6,0 s	10,0 s (p99)	Já liquidou
Suspeita	–	–	30 a 60 min

A pagadora tem 1,5 s para autorizar. É aí que o detector decide se desvia para investigação.

Os tempos publicados do Pix

Intervalo	p50	p95 / p99	O que ele limita
Pagadora	0,9 s	1,5 s (p95)	Autorizar ou desviar
Ponta a ponta	6,0 s	10,0 s (p99)	Já liquidou
Suspeita	—	—	30 a 60 min

**Em 10 s a transferência já liquidou.
Depois disso não há o que desviar.**

Os tempos publicados do Pix

Intervalo	p50	p95 / p99	O que ele limita
Pagadora	0,9 s	1,5 s (p95)	Autorizar ou desviar
Ponta a ponta	6,0 s	10,0 s (p99)	Já liquidou
Suspeita	–	–	30 a 60 min

**Desviada dentro do 1,5 s, a
transferência ganha de 30 a 60 min de
investigação.**

- **Precisão e recall: em lote, depois do fato**
- **Nenhum artefato aberto pontua contra a janela**



Quatro geradores, e o que cada um mede

Trabalho	Domínio	Cadeia	Tempo	Prazo
PaySim	Din. móvel	–	1 h por passo	×
pix-fraud-br	Pix	1 salto	Carimbo	×
Tide	Bancária	2–5	1–48 h	×
PixGuard-Sim	Pix	1 e multi	Por evento	✓

Dinheiro móvel, um passo por hora. O desenho publicado só gera tráfego legítimo.

Quatro geradores, e o que cada um mede

Trabalho	Domínio	Cadeia	Tempo	Prazo
PaySim	Din. móvel	–	1 h por passo	×
pix-fraud-br	Pix	1 salto	Carimbo	×
Tide	Bancária	2–5	1–48 h	×
PixGuard-Sim	Pix	1 e multi	Por evento	✓

Derivado do PaySim, em termos de Pix. Para na primeira conta laranja.

Quatro geradores, e o que cada um mede

Trabalho	Domínio	Cadeia	Tempo	Prazo
PaySim	Din. móvel	–	1 h por passo	×
pix-fraud-br	Pix	1 salto	Carimbo	×
Tide	Bancária	2–5	1–48 h	×
PixGuard-Sim	Pix	1 e multi	Por evento	✓

Lavagem em cadeia, de 1 a 48 h entre saltos. O análogo aberto mais próximo do MED.

Quatro geradores, e o que cada um mede

Trabalho	Domínio	Cadeia	Tempo	Prazo
PaySim	Din. móvel	–	1 h por passo	×
pix-fraud-br	Pix	1 salto	Carimbo	×
Tide	Bancária	2–5	1–48 h	×
PixGuard-Sim	Pix	1 e multi	Por evento	✓

Nenhum mede se a decisão chega a tempo

01

A proposta



Quatro cenários

- **Tomada de conta**
- **Coação**
- **Falsa devolução MED**
- **Cadeia de laranjas**

Quatro cenários

- **Tomada de conta**
- **Coação**
- **Falsa devolução MED**
- **Cadeia de laranjas**

**Sessão remota na conta da vítima.
Um salto, e é o que o dado aberto já traz.**

Quatro cenários

- Tomada de conta
- **Coação**
- Falsa devolução MED
- Cadeia de laranjas

A vítima paga sob ameaça, do próprio aparelho. Acende só o recebedor novo.

Quatro cenários

- Tomada de conta
- Coação
- Falsa devolução MED
- Cadeia de laranjas

Devolução falsa. O golpista usa o próprio MED para mover o dinheiro, em até cinco camadas.

Quatro cenários

- Tomada de conta
- Coação
- Falsa devolução MED
- Cadeia de laranjas





Dispersa dinheiro já tomado. O primeiro salto ainda parece tomada de conta.

Que sinal cada cenário carrega

legítimo	0,06	0,03	0,00
tomada de conta	0,61	1,00	1,00
cadeia de laranjas	0,26	0,62	0,34
devolução MED	0,37	0,53	0,00
coação	0,00	1,00	0,00
	aparelho trocado	recebedor novo	sessão remota

**Na coação, só o
recebedor novo.**

Arquitetura



1
Janela

2
Fontes

3
Cenários

4
Veredito

1 • Janela

1 • Janela

2 • Fontes

3 • Cenários

4 • Veredito

JANELA

por evento

a liquidação é final na borda direita



transferência irrevogável

- Traz o instante da irrevogabilidade


2 • Fontes

1 • Janela

2 • Fontes

3 • Cenários

4 • Veredito



- Um adaptador por gerador
- Quinze campos, iguais para as três

3 · Cenários

1 · Janela

2 · Fontes

3 · Cenários

4 · Veredito

CENÁRIOS

Tomada de conta
um salto

Cadeia de laranjas
4 saltos

Falsa devolução MED
5 saltos

Coação
um salto


4 · Veredito

1 · Janela

2 · Fontes

3 · Cenários

4 · Veredito



- Latência medida
- Prazo de 1,5 s, do Manual do Pix

Uma detecção só conta se as duas valerem

**1 • sinalizou
a nota passou do limiar, numa fraude verdadeira**

**2 • decidiu a tempo
a latência medida coube no prazo**

02

Avaliação



Os mesmos 1.000 eventos para os cinco

- 150 fraudes e 850 legítimas
- 15% de fraude na fatia

PR-AUC dos cinco detectores

Mesmos 1.000 eventos, 150 fraudes. Ao acaso: 0,150.



Os dois de nuvem chegam a 0,85.

Quantas chegam no prazo

Das 150 fraudes: sinalizadas E decididas em 1,5 s.



Dos dois de nuvem, nenhuma decisão cabe no orçamento.

A latência medida, contra o prazo



Os dois de
nuvem decidem
depois da linha.

Quantas fraudes cada um achou

- **DeepSeek v4-pro: 112 de 150**
- **Random forest: 93 de 150**
- **Falsos positivos: 30 contra 1**

Fatia de 1.000 eventos: 150 fraudes e 850 legítimas.

**No p95, o modelo de nuvem mais forte
gasta**

689%

do orçamento de 1,5 s.

Limitações

- **Dados sintéticos**
- **Prazo medido em uma máquina só**

03

Conclusões



A contribuição

- **Protocolo de avaliação sensível ao prazo**
- **Gerador nativo de Pix com tempo de liquidação**

Os dois que acham mais fraude não respondem dentro dos 1,5 s; o que responde a tempo acha menos.



Obrigado!

Perguntas são bem-vindas

AUTOR DE CONTATO

Cristhian Kapelinski

cristhianavila.aluno@unipampa.edu.br



Artigo



Artefato

Laboratório

Apoio



FAPERGS

Fundação de Amparo à Pesquisa do Estado do Rio Grande do Sul



Tudo é sintético. E daí?

- **Pix real** é privado: nada aqui é taxa de produção
- **A latência** é cronometrada, não configurada
- **O prazo** é do regulador: 1,5 s, p95
- **Três fontes** duas feitas por outros grupos

O achado central vem do relógio, não do dado.

15% de fraude na fatia?

- **1.000 eventos** 150 fraudes, 850 legítimas
- **Ao acaso** 0,150 aqui, e não 1,19%
- **Por quê** a 1,19% sobrariam dezenas de fraudes
- **O preço** precisão daqui não é taxa de produção

A latência e a ordem dos detectores não mudam.

Uma máquina, uma rede

- **Local** Ryzen 5 8600G e RTX 5060 Ti de 16 GB
- **Nuvem** a latência inclui a ida e a volta
- **3,4× e 6,9×** do orçamento: hardware não fecha
- **Encolheria** com quantização ou modelo na casa

Veredito da máquina declarada: re-medir, não herdar.

O prazo é do regulador

- **1,5 s** p95 da autorização da pagadora
- **0,9 s** p50 da mesma linha do manual
- **30 a 60 min** janela larga, se já há suspeita
- **Liquidação** no gerador, 300 a 1.999 ms

Nenhuma linha é prazo de detecção: elas limitam participante.

“No prazo” é recall?

- É recall restrita ao que chega a tempo
- **Não é** estimador novo: é uma condição a mais
- **Tabulares** decidem em $< 0,01$ ms: é a recall deles
- **Só separa** com latência perto da janela

Acurácia e prazo saem juntos, nunca sozinhos.

0,993 no prazo, PR-AUC 0,160

- **LLM local** sinaliza 149 das 150: recall 0,993
- **E também** 850 falsos em 850 legítimas
- **Precisão** 0,149: a tempo, e errando quase tudo
- **Leitura** a fração no prazo não substitui acurácia

Chegar a tempo e acertar são duas perguntas.

0,920 ou 0,137 no pix-fraud-br?

- **0,920** XGBoost, atributos próprios da fonte
- **0,137** random forest, esquema comum
- **A causa** saldo prévio: 2/3 da importância lá
- **Entre fontes** 0,743 aqui cai para 0,021 lá

Uma PR-AUC fala de detector, dado e esquema.

Sinais por cenário

Cenário	Aparelho trocado	Recebedor novo	Sessão remota
Legítimo	0,06	0,03	0,00
Tomada de conta	0,61	1,00	1,00
Cadeia de laranjas	0,26	0,62	0,34
Devolução MED	0,37	0,53	0,00
Coação	0,00	1,00	0,00

Fração dos eventos com o sinal. O detector tabular não vê a sessão remota.

As quinze colunas do evento

Grupo	Campos	De fonte externa
Identidade e rótulo	3	da fonte
Contas	3	duas da fonte
Linha do tempo	3	início da fonte
Atributos do detector	4	só o valor
Sinais nativos do Pix	2	sempre zero

Das quatro colunas do detector, só o valor sobrevive ao mapeamento.

Coação foi feita indetectável?

- **Não** o valor sobe e o recebedor é novo: 1,00
- **Pobre** em duas das quatro colunas visíveis
- **Aparelho** não muda; velocidade abaixo da média
- **Recall** 0,146 [0,069, 0,284] em 41 eventos

Livre de sinal nessas duas colunas, não em geral.

n por cenário: 53, 60, 39 e 41

Cenário	Recall	IC 95%	n
Tomada de conta	0,736	0,604 a 0,836	53
Cadeia de laranjas	0,433	0,316 a 0,559	60
Falsa devolução MED	0,282	0,165 a 0,438	39
Coação	0,146	0,069 a 0,284	41

Os extremos não se sobrepõem; laranjas e MED, sim.

O detector de grafo

- **GraphSAGE** duas camadas; ajusta em 2,4 s
- **PR-AUC** 0,247 no nosso e 0,011 no Tide-HI
- **Recall 0,850** com precisão 0,082: sinaliza demais
- **Grau médio** 20 aqui e 29 no Tide-HI

Uma arquitetura pequena: não é veredito sobre grafo.

Os dois prompts

- **Direto** só a probabilidade; teto de 8 tokens
- **Raciocínio** três frases e o veredito; teto 320
- **Gasto** 5 e 8 tokens local; 171 e 284 na nuvem
- **Nomeados** os quatro sinais, no próprio prompt

O teto não prende: separa quanto cada um fala.

Três fontes independentes, um esquema

Fonte	Licença	Ilícito	Papel
PixGuard-Sim	MIT	1,19%	única com coação e MED multi-salto
pix-fraud-br	ODC-BY	0,77%	salto único, com baseline publicado
Tide HI / LI	CC BY 4.0	HI 0,19% LI 0,10%	cadeias multi-salto, ilícito mais raro

Só o valor sobrevive; as outras três são injetadas.

Os três detectores tabulares

16.193 eventos · 193 fraudes · uma linha por transferência

Detector	F1	PR-AUC	Recall	Latência
Regra fixa	44,3%	0,431	34,2%	< 0,01
Regressão logística	63,9%	0,706	51,3%	< 0,01
Random forest	68,4%	0,743	62,2%	< 0,01

PR-AUC: área sob a curva precisão-recall.
O prazo ainda não separa nada entre os três.