

SBSEG 2026 · BÚZIOS, RJ · 1 A 4 DE SETEMBRO

RAGtrap:

Revogação de fontes e consulta indexada
de proveniência para corpora RAG
envenenados



Cristhian Kapelinski · Diego Kreutz
AI Horizon Labs · UNIPAMPA · WTICG completo



AI HORIZON
LABS
Explorando Novas Fronteiras da Inteligência Artificial



RAG

1 · Pergunta



2 · Busca




3 · Geração



O conteúdo vem da base, não da memória.

51%

dos líderes de TI já usavam
RAG · 2024




377%

de crescimento dos bancos
vetoriais em um ano · 2025




Parte da base vem de fora do seu controle.



Envenenamento da base

- 5 passagens adversárias por pergunta
- Resposta do atacante em 90% das perguntas
- Só os recuperados entram no contexto



Limpar a base pede duas operações

- **Ligar o trecho a quem o entregou**
- **Apagar tudo daquela fonte, e só isso**

GMTP, o filtro na consulta

Descarta a suspeita.


Nada sai da base.

Trabalhos relacionados


Família e trabalhos	Revoga?
Ataque, na ingestão PoisonedRAG (2025)	×
Filtro na consulta GMTP (2025)	×
Atribuição pós-incidente RAGForensics (2025), RAGOrigin (2026)	×
Atestação na admissão (2026) VectorSmuggle, MerkleSpeech, RAGShield	×
RAGtrap: ingestão e pós-incidente	✓

01

0 mecanismo




Arquitetura




Ingestão

Roda uma vez por trecho, e a proveniência nasce aí.




Registros e índices

O registro assinado entra em dois índices.



Rastreio e revogação

Só rodam com a fonte já comprometida.



Índice de conteúdo

“Quem forneceu este texto?”

chave: hash do texto

valor: os registros com esse hash

Índice de fonte

“Que mais essa fonte forneceu?”

chave: a fonte
valor: os trechos dela


Onde a busca exata falha

A atribuição exige bytes idênticos.

- Texto de log, ou reescrito, não bate
- Depende de como o texto foi obtido
- Rer ler o trecho na base sempre resolve

02

Avaliação experimental



Configuração

Base limpa BEIR NQ: 2.681.468 passagens

Ataque PoisonedRAG: 500 passagens

Suspeitos 1.000 passagens recuperadas pela busca

Máquina Ryzen 5 8600G, 32 GB, RTX 5060 Ti

Como cada um funciona

RAGtrap

Lê o registro da ingestão. Não olha o texto.

RAGForensics

Juiz LLM: uma chamada por passagem.

RAGOrigin


Duas pontuações, corta por limiar.

0 custo de atribuir um suspeito

	RAGtrap	RAG Forensics	RAG Origin
Latência por suspeito	78,7 μ s	1,7 s	64,5 ms
Chamadas ao modelo	0	1.000	2.000
Custo relativo	1×	21.026×	819×

São tarefas diferentes.

O que se leva junto ao limpar



Apagar o documento: 1.290 trechos, 672 benignos.
Revogar pela fonte: 618, nenhum benigno.

0 custo de assinar

Assinar um
trecho leva

55,7 μ s

ou 17.961 por
segundo

Cada registro
ocupa

575 B

64 deles são a
assinatura

Ed25519: 1,9× o HMAC, e qualquer um verifica.

Limitações

- **Um ataque, sobre um corpus**
- **Proveniência atribuída, não observada**
- **Protótipo em memória, sem banco vetorial**
- **Chave do operador roubada, assinatura forjável**

03

Conclusões



Contribuição

- **Proveniência assinada por trecho**
- **Dois índices: conteúdo e fonte**

Impacto

- **Consulta no lugar de investigação**



Obrigado!

Perguntas são bem-vindas

AUTOR DE CONTATO

Cristhian Kapelinski

`cristhianavila.aluno@unipampa.edu.br`

APOIO



Artefato



Site do lab



Artigo

